

ТЕМА 1. ОПИСАТЕЛЬНАЯ СТАТИСТИКА

(Семинар 1-3)

Рассмотрим случайную величину, наблюдаемую в некотором случайном эксперименте,

$$\xi(\omega) : \Omega \rightarrow R$$

с функцией распределения $F_\xi(x) = P(\xi < x)$.

Распределение этой случайной величины нам частично или полностью неизвестно.

Все множество значений, которые может принять изучаемая случайная величина, называют **генеральной совокупностью**.

Проведя n раз этот эксперимент в одинаковых условиях, получим числа $x_1, x_2, \dots, x_n$ — значения наблюдаемой случайной величины в первом, втором и т.д. экспериментах.

Набор $x_1, x_2, \dots, x_n$ называется **выборкой** из генеральной совокупности.

При этом выбор производят при выполнении следующих условий:

- случайным образом;
- независимо друг от друга;
- из одной и той же генеральной совокупности.

Количество элементов в выборке n называют **объемом выборки**.

Выборку, все элементы которой расположены в порядке возрастания, называют **вариационным рядом**:

$$x_1^*, \dots, x_n^*.$$

При статистической обработке данных, в том случае, когда есть основание считать, что изучаемая случайная величина дискретная, для нее строят сгруппированный статистический ряд, т.е. таблицу вида:

x_i^*	x_1^*	x_2^*	$\dots$	x_q^*
p_i^*	p_1^*	p_2^*	$\dots$	p_q^*

$$p_i^* = \frac{n_i}{n}, \quad \sum_{i=1}^q p_i^* = 1$$

Здесь x_i^* – **неповторяющиеся** выборочные значения случайной величины ξ , расположенные в порядке возрастания, значения n_i – это число, показывающее, сколько раз значение x_i^* встретилось в выборке (частота выборочного значения), p_i^* – **относительная частота выборочного значения**.

Полигоном частот (Рис. 1.1) называется ломаная с узлами в точках

$$(x_1^*, n_1), \dots, (x_q^*, n_q).$$




Рис. 1.1. Полигон частот

Ломаная с узлами в точках $(x_1^*, p_1^*), \dots, (x_q^*, p_q^*)$ называется **полигоном относительных частот**.

Эмпирическая функция распределения $F_n^*(x)$, которая служит оценкой теоретической функции распределения $F_\xi(x)$ для **дискретных случайных** величин и находится следующим образом (Рис. 1.2):

$$F_n^*(x) = \frac{\nu(x)}{n},$$

где $\nu(x)$ – число элементов выборки, меньших x .

$$F_n^*(x) = \begin{cases} 0, & \text{если } x \leq x_1^*; \\ p_1^*, & \text{если } x_1^* < x \leq x_2^*; \\ \dots & \dots \\ \sum_{i=1}^{k-1} p_i^*, & \text{если } x_{k-1}^* < x \leq x_k^*; \\ \dots & \dots \\ 1, & \text{если } x_q^* < x. \end{cases} \quad (1.2)$$




Рис. 1.2. Эмпирическая функция распределения дискретной случайной величины

Интервальный статистический ряд

Для непрерывной случайной величины строят **интервальный статистический ряд**.

На первом шаге находят число интервалов r , на которые разбивается отрезок $[x_{\min}, x_{\max}]$, длина которого называется **размахом выборки** $R = x_{\max} - x_{\min}$, где

$$x_{\min} = \min\{x_1, x_2, \dots, x_n\}, \quad x_{\max} = \max\{x_1, x_2, \dots, x_n\}.$$

Количество интервалов группировки данных r часто определяют по формуле Стерджесса:

$$r = \lfloor 1 + \log_2 n \rfloor, \quad (1.3)$$

то есть как целая часть числа $1 + \log_2 n$.

Границы $\tilde{x}_i$ интервалов J_i , $i = 1, \dots, r$ находят по формулам:

- $J_1 = [\tilde{x}_1, \tilde{x}_2]$, $J_i = (\tilde{x}_i, \tilde{x}_{i+1}]$, $i = 2, \dots, r$,
- $\tilde{x}_i = x_{\min} + (i - 1)\delta$, $x_{r+1} = x_{\max}$,
- $\delta = (x_{\max} - x_{\min})/r$ - длина интервала.

Тогда интервальный ряд можно представить таблицей:

J_i	$[\tilde{x}_1, \tilde{x}_2]$	$(\tilde{x}_2, \tilde{x}_3]$	$\dots$	$(\tilde{x}_r, \tilde{x}_{r+1}]$
$\hat{p}_i^*$	$\hat{p}_1^*$	$\hat{p}_2^*$	$\dots$	$\hat{p}_r^*$

График эмпирической функции распределения $F_n^*(x)$ называют **кумулятой** или **кумулятивной кривой** (Рис. 1.3) и находят по следующему правилу:

Пусть n_i - число выборочных значений, попавших в интервал J_i (частота), $\hat{p}_i^*$ - относительная частота, тогда

$$\tilde{p}_i^* = \frac{n_i}{n}, \quad \sum_{i=1}^r \tilde{p}_i^* = 1 \quad (1.4)$$




Рис. 1.3. Кумулятивная кривая

Эмпирическую плотность $f_n^*(x)$, являющуюся оценкой теоретической плотности распределения генеральной совокупности, определяют по следующему правилу.

$$f_n^*(x) = \begin{cases} 0, & \text{если } x \leq \tilde{x}_1^*; \\ p_1^*/\delta, & \text{если } \tilde{x}_1^* < x \leq \tilde{x}_2^*; \\ p_2^*/\delta, & \text{если } \tilde{x}_2^* < x \leq \tilde{x}_3^*; \\ \dots & \dots \\ p_r^*/\delta, & \text{если } \tilde{x}_r^* < x \leq \tilde{x}_{r+1}^*; \\ 0, & \text{если } \tilde{x}_{r+1}^* < x. \end{cases} \quad (1.5)$$

График эмпирической плотности называют **гистограммой** (Рис. 1.4).




Рис. 1.4. Гистограмма

Выборочные характеристики

Выборочным моментом порядка r называют величину:

$$\overline{x^r} = \frac{1}{n} \sum_{i=1}^n x_i^r. \quad (1.6)$$

Выборочный момент порядка 1 вычисляется по формуле:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1.7)$$

и называется **выборочным средним**.

Выборочным центральным моментом порядка r называют величину:

$$\mu^r = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^r. \quad (1.8)$$

Выборочный центральный момент порядка 2 обозначается через s^2 , вычисляется по формуле:

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (1.9)$$

и называется **выборочной дисперсией**.

Величину

$$\tilde{s}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (1.10)$$

называют **исправленной выборочной дисперсией**.

Величины s^2 и $\tilde{s}^2$ связаны между собой соотношением

$$\tilde{s}^2 = \frac{n}{n-1} s^2. \quad (1.11)$$

Выборочная квантиль x_p порядка p определяется как элемент вариационного ряда с номером $[np] + 1$, $p \in (0, 1)$. Чаще всего используются квантили порядка 0,25; 0,5; 0,75, делящие ряд на 4 части, они называются **квартилями** и обозначаются соответственно Q_1 , Q_2 , Q_3 . Квартиль Q_2 называется **выборочной медианой**. (Рис. 1.5)

Выбросы это наблюдения, которые резко отличаются от остальных данных в выборке и не соответствуют общей закономерности. Выброс может быть как следствием ошибки (измерения, записи), так и результатом реального, но редкого события.

Идентификация выбросов по методу Тьюки:




Рис. 1.5. Квартили

- Величина $IQR = Q_3 - Q_1$ называется **межквартильным размахом**:
- Элементы выборки, значения которых меньше $Q_1 - 1,5 \cdot IQR$ или больше $Q_3 + 1,5 \cdot IQR$ считаются **выбросами**.
- Элементы выборки, значения которых меньше $Q_1 - 3 \cdot IQR$ или больше $Q_3 + 3 \cdot IQR$ считаются «**экстремальными**» **выбросами**.

Для визуального представления выбросов служит схема "ящик с усами" (boxplot).




Рис. 1.6. Ящик с усами

Идентификация выбросов по методу z -оценок

- Предполагается, что выборка извлечена из нормальной генеральной совокупности.
- Элемент выборки x_i считается выбросом, если величина

$$z_i = \frac{x_i - \bar{x}}{s} \quad (1.12)$$

принимает значение, лежащее вне отрезка $[-3; 3]$.

Выборочной модой называется элемент выборки, который встречается чаще других.

В качестве выборочной меры относительного разброса используется **выборочный коэффициент вариации**, который вычисляется по формуле:

$$v = \frac{s}{\bar{x}}. \quad (1.13)$$

Интерпретация коэффициента вариации

В большинстве социально-экономических и технических исследований придерживаются следующей шкалы (для CV%):

Менее 10% - низкая изменчивость (совокупность однородна, среднее значение высоконадежно),

10% – 25% - средняя изменчивость (умеренный разброс, допустимые колебания),

более 25% - высокая изменчивость (совокупность неоднородна, среднее значение нетипично для большинства элементов),

более 33% - критический порог (часто используется в физических измерениях, данные считаются крайне разрозненными).

Форму распределения можно оценить с помощью следующих выборочных характеристик.

Величину $\tilde{A}$ называют **выборочным коэффициентом асимметрии**. Она представляет собой характеристику симметрии распределения генеральной совокупности относительно математического ожидания и вычисляется по формуле:

$$\tilde{A} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}. \quad (1.14)$$

Графическая и содержательная интерпретация значения коэффициента асимметрии (Рис. 1.7.):

Значение	Название	Характер распределения	Соотношение средних значений
$\tilde{A} < 0$	Отрицательная (левосторонняя) асимметрия	Длинный хвост уходит влево	$\bar{x} < X_{me} < x_{mo}$
$\tilde{A} = 0$	Симметричное	Хвосты примерно равны	$\bar{x} = X_{me} = x_{mo}$
$\tilde{A} > 0$	Положительная (правосторонняя) асимметрия	Длинный хвост уходит вправо	$\bar{x} > X_{me} > x_{mo}$




Рис. 1.7. Интерпретация коэффициента асимметрии

Величину $\tilde{E}$ называют **выборочным коэффициентом эксцесса**. Она характеризует остроту пика графика плотности распределения и вычисляется по формуле:

$$\tilde{E} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4} - 3. \quad (1.15)$$

Геометрическая интерпретация коэффициента эксцесса: (Рис. 1.8.)




Рис. 1.8. Интерпретация эксцесса

Функции R studio

Некоторые математические функции:

- **abs(x)** — модуль числа x ;
- **exp(x)** — показательная функция;
- **log(x)** — натуральный логарифм;
- **log2(x)** — логарифм по основанию 2;
- **sin(x)** — синус;
- **cos(x)** — косинус;
- **ceiling(x)** округляет x вверх до ближайшего целого числа;
- **floor(x)** округляет x вниз до ближайшего целого числа.

Логические операции:

- **<** — меньше;
- **<=** — меньше или равно;
- **>** — больше;
- **>=** — больше или равно;
- **==** — равно;
- **!=** — не равно;
- **!A** — не A ;
- **A | B** — A или B ;
- **A & B** — A и B .

Работа с массивами:

- **c()** — вектор, например, **c(1, 2, 0, 1)** задает вектор (1, 2, 0, 1);
- **X[-2]** убирает из X второй столбец,
- **X[-c(2,4)]** — убирает из X второй и четвертый столбец,
- **X[-c(2:4)]** — убирает из X столбцы со второго по четвертый,

- `X[-c(2,4),]` — убирает из X вторую и четвертую строки;
- `sort(X)` — упорядочение X по возрастанию;
- `sort(X, decreasing = TRUE)` — по убыванию;
- `sum(X)` — сумма элементов X ;
- `cumsum(X)` — вектор накопленных сумм элементов X ;
- `prod(X)` — произведение элементов X ;
- `cumprod(X)` — вектор накопленных произведений элементов X ;
- `rank(X, ties.method = "M")` — набор рангов по числовому набору X ; в случае повторяющихся элементов ранг элементов в связке будет определяться методом M : средним рангом ($M = \text{average}$), по порядку ($M = \text{first}$), в обратном порядке ($M = \text{last}$), случайным ($M = \text{random}$), максимальным ($M = \text{max}$) или минимальным ($M = \text{min}$);
- `subset(X, cond)` выбирает из X согласно условию `cond`;
- `nrow(X)` — количество строк в X ;
- `ncol(X)` — количество столбцов в X ;
- `as.Date("YYYY-M-D")` — интерпретировать значение в формате даты;
- `sample_n(X, m)` выбирает из X случайно m элементов (используется пакет `dplyr`);
- `sample_frac(X, p)` выбирает из X случайно $100p\%$ элементов (используется пакет `dplyr`);

Основные функции описательной статистики Пусть X — выборка.

- `mean(X)` — выборочное среднее;
- `var(X)` — выборочная дисперсия;
- `sd(X)` — выборочное среднеквадратическое (стандартное) отклонение;
- `min(X)` — минимальный элемент;

- **max(X)** — максимальный элемент;
- **length(X)** — объем;
- **median(X)** — медиана;
- **quantile(X, p)** — квантиль для выборки X уровня (порядка) p :
при $p = 0$ — минимальный элемент $\min(X)$;
при $p = 0.25$ — первый квартиль Q_1 ; при $p = 0.5$ — второй квартиль Q_2 (медиана);
при $p = 0.75$ — третий квартиль Q_3 ;
при $p = 1$ — максимальный элемент $\max(X)$;
- **quantile(X)** выводит квантили уровней 0, 0.25, 0.5, 0.75, 1;
- **IQR(X)** — межквартильный размах;
- **summary(X)** выводит минимальный элемент выборки, первый квартиль, медиану, выборочное среднее, третий квартиль и максимальный элемент.
- **skewness(X)** — выборочный коэффициент асимметрии (**используется пакет e1071**);
- **kurtosis(X)** — выборочный коэффициент эксцесса (**используется пакет e1071**);
- **table(X)** строит точечный вариационный ряд по X ;
- **table(cut(X, breaks = m))** строит интервальный вариационный ряд по X с m интервалами группировки;
- **ecdf(X)** — эмпирическая функция распределения, построенная по X ;
- **ecdf(X)(x)** — значение эмпирической функции распределения в точке x , построенной по X ;
- **plot(ecdf(X))** строит график эмпирической функции распределения;
- **hist(X, freq = TRUE)** строит гистограмму частот для выборки X ;

- **hist(X, freq = TRUE, breaks = m)** создает гистограмму частот для выборки X с m интервалами группировки (есть особенности);
- **boxplot(X, range = 0)** строит «ящик с усами»; «усы» соответствуют минимальному и максимальному элементам, «ящик» соответствует первому квартилю, медиане и третьему квартилю.
- **boxplot(X, range = 1.5)** или **boxplot(X)** «усы» отстоят на полтора межквартильного расстояния от «ящика», а возможные отдельные точки отображают выбросы;
- **qqPlot(X)** строит график QQ plot, сравнивающий выборочные квантили с квантилями нормального распределения (**используется пакет car**);
- **aggregate(X, list(Y), fun, na.rm = TRUE)** агрегирует X по значениям Y в соответствии с функцией fun , исключая пропущенные наблюдения.

Решение типовых задач

ТЗ 1.1.

Имеются следующие данные о количественном составе 60 семей:

2, 3, 3, 1, 4, 2, 3, 3, 1, 5, 2, 4, 3, 2, 2, 1, 2, 3, 4, 5, 2, 2, 1, 3, 4, 3, 3, 3, 6, 6,

3, 3, 6, 1, 3, 4, 3, 4, 4, 5, 3, 3, 2, 2, 1, 3, 2, 5, 5, 2, 4, 3, 6, 1, 2, 2, 3, 1, 3, 4.

Постройте точечный вариационный ряд, эмпирическую функцию распределения.


Решение:

Строим сгруппированный точечный вариационный ряд для дискретной случайной величины:

x_i^*	1	2	3	4	5	6
p_i^*	8/60	14/60	20/60	9/60	5/60	4/60

Находим эмпирическую функцию распределения для сгруппированного ряда:

$$F_n^*(x) = \begin{cases} 0, & \text{при } x \leq 1, \\ 8/60, & \text{при } 1 < x \leq 2, \\ 22/60, & \text{при } 2 < x \leq 3, \\ 42/60, & \text{при } 3 < x \leq 4, \\ 51/60, & \text{при } 4 < x \leq 5, \\ 56/60, & \text{при } 5 < x \leq 6, \\ 1, & \text{при } x > 6. \end{cases}$$



ТЗ 1.2. Анализируется выборка из 100 малых предприятий региона. Цель исследования — измерение коэффициента соотношения заемных и собственных средств (x_i) на каждом i -ом предприятии:

5,56 5,45 5,48 5,45 5,37 5,46 5,59 5,61 5,31
5,46 5,61 5,11 5,41 5,31 5,57 5,33 5,11 5,54
5,34 5,53 5,46 5,41 5,48 5,39 5,11 5,42 5,48
5,49 5,40 5,45 5,49 5,68 5,51 5,50 5,68 5,21
5,38 5,47 5,46 5,19 5,60 5,63 5,48 5,27 5,22
5,33 5,49 5,50 5,54 5,40 5,58 5,42 5,29 5,05
5,79 5,65 5,70 5,71 5,85 5,44 5,47 5,48 5,47
5,67 5,71 5,73 5,05 5,35 5,72 5,49 5,61 5,57
5,54 5,39 5,32 5,21 5,73 5,59 5,38 5,25 5,26
5,27 5,64 5,20 5,23 5,33 5,37 5,24 5,55 5,60
5,39 5,43 5,36 5,38 5,58 5,79 5,55 5,81 5,50
5,81

Требуется построить гистограмму и кумуляту (эмпирическую функцию распределения).

Решение:

Построим интервальный вариационный ряд. Для этого определим по выборке $x_{\min} = 5,05$ и $x_{\max} = 5,85$. Разобьем весь диапазон $[x_{\min}, x_{\max}]$ на k равных интервалов:

$$k = [1 + \log_2 100] = 8.$$


Определим длину интервала

$$\delta = \frac{x_{\max} - x_{\min}}{k} = \frac{5,85 - 5,05}{8} = 0,1.$$


Составим таблицу.

Номер интервала	интервалы	n_i	p_i^*	$F_n^*(x)$	$f_n^*(x)$
1	[5,05;5,15]	5	0,05	0,05	0,5
2	(5,15;5,25]	8	0,08	0,13	0,8
3	(5,25;5,35]	12	0,12	0,25	1,2
4	(5,35;5,45]	20	0,20	0,45	2
5	(5,45;5,55]	26	0,26	0,71	2,6
6	(5,55;5,65]	15	0,15	0,86	1,5
7	(5,65;5,75]	10	0,10	0,96	1,0
8	(5,75;5,85]	4	0,04	1	0,4

Нарисуем гистограмму $f_n^*(x)$.



Нарисуем график эмпирической функции распределения (кумуляту):



ТЗ 1.3. Определите выборочное среднее, выборочную дисперсию, исправленную выборочную дисперсию, моду и медиану для выборки: 5, 6, 8, 2, 3, 1, 1, 5.

Решение: Представим выборку в виде точечного вариационного ряда.

x_i	1	2	3	5	6	8
n_i	2	1	1	2	1	1

Объем выборки $n = 8$. Выборочное среднее

$$\bar{x} = \frac{1}{8}(1 \cdot 2 + 2 \cdot 1 + 3 \cdot 1 + 5 \cdot 2 + 6 \cdot 1 + 8 \cdot 1) = 3,875.$$

Выборочная дисперсия

$$s^2 = \frac{1}{8}(1^2 \cdot 2 + 2^2 \cdot 1 + 3^2 \cdot 1 + 5^2 \cdot 2 + 6^2 \cdot 1 + 8^2 \cdot 1) - 3,875^2 \approx 5,609.$$

Исправленная выборочная дисперсия

$$\tilde{s}^2 = \frac{n}{n-1}s^2 = \frac{8}{7}s^2 = 6,41.$$

Два элемента выборки имеют частоту 2, большую, чем остальные (частота 1), следовательно, в выборке две моды $\{1, 5\}$.

Так как $n = 8$, то медиана (квартиль порядка 0,5):

$$Q_2 = \frac{1}{2}(3 + 5) = 4.$$

Задания практикума

В задачах 1.1 - 1.4 определить объем и размах выборки, а также построить точечный вариационный ряд.

1.1. 5, 3, 7, 10, 5, 5, 2, 10, 7, 2, 7, 7, 4, 2, 4.

1.2. 3, 8, 1, 3, 6, 5, 2, 2.

1.3. 11, 15, 12, 0, 16, 17, 18, 19, 12, 13, 16, 8, 9, 14, 5, 11, 3.

1.4. 17, 18, 16, 16, 6, 11, 17, 18, 19, 17, 15, 17, 19, 18, 16, 16, 18, 18.

В задачах 1.5 - 1.7 требуется составить интервальный вариационный ряд.

1.5.

17	19	23	21	15	16	13	20	18	15	18
20	14	20	16	14	20	19	15	19	16	19
15	22	21	12	10	21	18	14	14	17	16
13	19	18	20	24	16	20	19	17	18	18
21	17	19	17	13	17	11	18	19	19	17

1.6.

38	60	41	51	53	42	45	21	53	60
68	52	47	46	49	49	14	57	54	59
77	47	28	48	58	58	42	58	61	30
61	35	47	72	41	41	44	55	30	40
67	65	39	48	43	43	54	42	59	50

1.7.

13,4	14,7	15,2	15,1	13	8,8	14,0	17,9	15,1	16,5	16,6
14,2	16,3	14,6	11,7	16,4	15,1	17,6	14,1	18,8	11,6	13,9
18,0	12,4	17,2	14,5	16,3	13,7	15,5	16,2	8,4	14,7	15,4
11,3	10,7	16,9	15,8	16,1	12,3	14,0	17,7	14,7	16,2	17,1
10,1	15,8	18,3	17,5	12,7	20,7	13,5	14,0	15,7	21,9	14,3
17,7	15,4	10,9	18,2	17,3	15,2	16,7	17,3	12,1	19,2	15,2

В задачах 1.8 - 1.9 построить полигон частот и график эмпирической функции распределения.

1.8.

x_i	15	16	17	18	19
n_i	1	4	5	4	2

1.9.

x_i	2	3	4	5	6	7	8
n_i	1	3	4	6	5	2	1

1.10. Постройте гистограмму и кумуляту для следующего интервального ряда:

I_i	[10; 20]	(20; 30]	(30; 40]	(40, 50]	(50; 60]	(60; 70]	(70; 80]
n_i	1	3	7	18	12	8	2

1.11. Определить эмпирическую плотность распределения работников предприятия по стажу их работы на данном предприятии. Постройте гистограмму и найдите средний стаж работы.

Стаж работы, лет	До 1	1 – 5	5 – 10	10 – 20	20 – 40
число работников	8	12	16	14	10

1.12. Путем устного опроса изучалось количество продукции, выпускаемой фирмой и реализуемой в магазине этой фирмы. Посетители давали оценку качества по десятибалльной шкале. Были получены следующие данные

Оценка качества	1 – 2	3 – 4	5 – 6	7 – 8	9 – 10
число оценок	3	8	36	89	45

Определить средний балл качества продукции, среднее квадратическое отклонение, показатели асимметрии и эксцесса

1.13. Проведите анализ данных годовых уровней прибыли трех компаний:

год	"Cherry computers"	"Lemon Motors"	"Orange Electronics"
1983	14,2	-6,2	37,5
1984	12,3	13,3	-10,6
1985	-16,3	-8,4	40,3
1986	15,4	27,3	5,4
1987	17,2	28,2	6,2
1988	10,3	14,5	10,2
1989	-6,3	-2,4	13,8
1990	-7,8	-3,1	11,5
1991	3,4	15,6	-6,2
1992	12,2	18,2	27,5

Найдите среднее значение и стандартное отклонение прибыли для каждой компании. Деятельность какой из компаний, по вашему мнению, более успешна?

- 1.14.** Администрацию универсама интересует оптимальный уровень запасов продуктов в торговом зале, а также среднемесячный объем покупок товаров, которые не являются предметом ежедневного потребления (например таких, как сода). Для выяснения этого вопроса менеджер универсама в течение января регистрировал частоту покупок 100-граммовых пакетов с содой и собрал следующие данные x_i :

4, 4, 9, 3, 3, 1, 2, 0, 4, 2, 3, 5, 7, 8,
10, 6, 6, 7, 3, 2, 9, 8, 1, 4, 2, 1, 0.

Постройте точечный вариационный ряд, определите его числовые характеристики. Какие рекомендации Вы бы дали администрации универсама.

Задачи для решения в RStudio

- 1.15.** Следующая таблица представляет собой часть базы данных о потребителях одного из сотрудников отдела продаж:

Уровень интереса к новым изделиям	Объем закупок в прошлом году, дол	Географический регион
Слабый	88 906	Запад
Слабый	88 906	Запад
Умеренный	396 808	Юг
Очень сильный	438 442	Юг
Слабый	2 486	Средний запад
Слабый	37 375	Запад
Очень сильный	2 314	Северо-восток
Умеренный	1 244 096	Средний запад
Слабый	857 248	Юг
Сильный	119 650	Северо-восток
Умеренный	711 514	Запад
Слабый	22 616	Запад

- Что является элементарной единицей в этом наборе данных?
- Определите вид данных: одномерные, двумерные, многомерные?

- Определите, какие из этих переменных количественные, а какие качественные?
- Это временной ряд или данные об одном временном срезе?

1.16. В файле **BankiRU.txt** приведены эффективные ставки по вкладам на сумму 100 тыс. руб., размещенным в 2020 г. сроком на один год, в 25 российских банках, которые входят в Топ-30 банков.

- Импортируйте в RStudio данные из файла BankiRU.txt.
- Определите вид статистического наблюдения.
- Определите объем выборки. Определите, что является элементарной единицей, какие признаки и по какой шкале были зарегистрированы.
- Постройте точечный и интервальный вариационный ряд для эффективной ставки.
- Вычислите выборочное среднее, дисперсию и квартили для эффективной ставки.
- Определите квантиль уровня 0.8, а также уровень квантиля для значения эффективной ставки 4.4%.
- Вычислите коэффициент вариации и дайте ему краткую интерпретацию.
- Вычислите коэффициенты асимметрии и эксцесса и размах вариации для эффективной ставки. Постройте гистограмму частот и «ящик с усами» для эффективной ставки. Опишите форму распределения.
- Сделайте содержательные выводы.
- Опишите форму распределения эффективной ставки по размещенным на один год вкладам на сумму 100 тыс. руб. по любым выбранным вами числовым характеристикам или графикам/диаграммам.
- Постройте $Q - Q$ plot сделайте выводы из вида графика.
- Проверьте наличие выбросов методом Тьюки и методом z-оценок.

1.17. В файле **JetFuelPrices.txt** приведена стоимость авиационного керосина ТС-1 (руб. без НДС за 1 т.) в аэропортах Российской Федерации в мае–июле 2020 г.:

- Импортируйте в RStudio данные из файла JetFuelPrices.txt.

- Определите средние и медианные цены на авиатопливо в мае, июне и июле.
- Извлеките случайные выборки разных объемов и постройте для них гистограммы частот для цены на авиатопливо в июле. Сделайте вывод о влиянии объема выборки на форму гистограммы.
- Постройте «ящички с усами» по ценам на авиатопливо отдельно в мае, июне и июле. Сравните диаграммы, указав наблюдаемые различия.
- Определите средние и медианные цены на авиатопливо в мае, июне и июле для каждого федерального округа (FedDistrict). Сделайте выводы.
- Постройте «ящик с усами» по ценам на авиатопливо в мае, июне и июле для Центрального федерального округа (Central). Сделайте выводы.
- Постройте «ящички с усами» по ценам на авиатопливо в мае для каждого федерального округа (FedDistrict). Сравните диаграммы, указав наблюдаемые различия.
- Опишите форму распределения стоимости 1 тонны авиационного керосина ТС-1 в аэропортах Центрального и Уральского федеральных округов в мае по коэффициенту асимметрии, «ящичку с усами» и графику Q–Q plot.
- Проверьте наличие выбросов методом Тьюки и методом z -оценок.